

最大似然估计

维基百科，自由的百科全书

在统计学中，**最大似然估计**，也称为**最大概似估计**，是用来估计一个概率模型的参数的一种方法。

目录

预备知识

最大似然估计的原理

注意

例子

离散分布，离散有限参数空间

离散分布，连续参数空间

连续分布，连续参数空间

性质

泛函不变性 (Functional invariance)

渐近线行为

偏差

历史

参见

参考文献

外部链接

预备知识

下边的讨论要求读者熟悉概率论中的基本定义，如概率分布、概率密度函数、随机变量、数学期望等。同时，还要求读者熟悉连续实函数的基本技巧，比如使用微分来求一个函数的极值（即极大值或极小值）。

最大似然估计的原理

给定一个概率分布 D ，已知其概率密度函数（连续分布）或概率质量函数（离散分布）为 f_D ，以及一个分布参数 θ ，我们可以从这个分布中抽出一个具有 n 个值的采样 X_1, X_2, \dots, X_n ，利用 f_D 计算出其似然函数：

$$\mathrm{lik}(\theta \mid x_1, \dots, x_n) = f_{\theta}(x_1, \dots, x_n).$$

若 D 是离散分布， f_{θ} 即是在参数为 θ 时观测到这一采样的概率。若其是连续分布， f_{θ} 则为 X_1, X_2, \dots, X_n 联合分布的概率密度函数在观测值处的取值。一旦我们获得 X_1, X_2, \dots, X_n ，我们就能求得一个关于 θ 的估计。最大似然估计会寻找关于 θ 的最可能的值（即，在所有可能的 θ 取值中，寻找一个值使这个采样的“可能性”最大化）。从数学上来说，我们可以在 θ 的所有可能取值中寻找一个值使得似然函数取到最大值。这个使可能性最大的 $\hat{\theta}$ 值即称为 θ 的**最大似然估计**。由定义，最大似然估计是样本的函数。

注意

- 这裡的似然函数是指 x_1, x_2, \dots, x_n 不变时，关于 θ 的一个函数。
- 最大似然估计不一定存在，也不一定唯一。

例子

离散分布，离散有限参数空间

考虑一个抛硬币的例子。假设这个硬币正面跟反面轻重不同。我们把这个硬币抛80次（即，我们获取一个采样 $x_1 = H, x_2 = T, \dots, x_{80} = T$ 并把正面的次数记下来，正面记为H，反面记为T）。并把抛出一个正面的概率记为 p ，抛出一个反面的概率记为 $1 - p$ （因此，这裡的 p 即相当于上边的 θ ）。假设我们抛出了49个正面，31个反面，即49次H，31次T。假设这个硬币是我们从一个装了三个硬币的盒子里头取出的。这三个硬币抛出正面的概率分别为 $p = 1/3, p = 1/2, p = 2/3$ 。这些硬币没有标记，所以我们无法知道哪个是哪个。使用**最大似然估计**，基于**二项分布中的概率质量函数**公式，通过这些试验数据（即采样数据），我们可以计算出哪个硬币的可能性最大。这个似然函数取以下三个值中的一个：

$$\mathbb{P}(H=49, T=31 \mid p = 1/3) = \binom{80}{49} (1/3)^{49} (1 - 1/3)^{31} \approx 0.000$$

$$\mathbb{P}(H=49, T=31 \mid p = 1/2) = \binom{80}{49} (1/2)^{49} (1 - 1/2)^{31} \approx 0.012$$

$$\mathbb{P}(H=49, T=31 \mid p = 2/3) = \binom{80}{49} (2/3)^{49} (1 - 2/3)^{31} \approx 0.054$$

我们可以看到当 $\hat{p} = 2/3$ 时，似然函数取得最大值。这就是 p 的最大似然估计。

离散分布，连续参数空间

现在假设例子1中的盒子中有无数个硬币，对于 $0 \leq p \leq 1$ 中的任何一个 p ，都有一个抛出正面概率为 p 的硬币对应，我们来求其似然函数的最大值：

$$\text{lik}(\theta) = f_D(H=49, T=80-49 \mid p) = \binom{80}{49} p^{49} (1 - p)^{31}$$

其中 $0 \leq p \leq 1$ 。我们可以使用**微分法**来求**最值**。方程两边同时对 p 取微分，并使其为零。

$$\begin{aligned} 0 &= \frac{d}{dp} \left(\binom{80}{49} p^{49} (1 - p)^{31} \right) \\ &\propto 49p^{48} (1 - p)^{31} - 31p^{49} (1 - p)^{30} \\ &= p^{48} (1 - p)^{30} [49(1 - p) - 31p] \end{aligned}$$

其解为 $p = 0, p = 1$ ，以及 $p = 49/80$ 。使可能性最大的解显然是 $p = 49/80$ （因为 $p = 0$ 和 $p = 1$ 这两个解会使可能性为零）。因此我们说**最大似然估计值**为 $\hat{p} = 49/80$ 。

这个结果很容易一般化。只需要用一个字母 t 代替49用以表达伯努利试验中的被观察数据（即样本）的“成功”次数，用另一个字母 n 代表伯努利试验的次数即可。使用完全同样的方法即可以得到**最大似然估计值**

$$\hat{p} = \frac{t}{n}$$

对于任何成功次数为 t ，试验总数为 n 的伯努利试验。

连续分布，连续参数空间

最常见的连续概率分布是正态分布，其概率密度函数如下：

$$f(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

现在有 n 个正态随机变量的采样点，要求的是一个这样的正态分布，这些采样点分布到这个正态分布可能性最大（也就是概率密度积最大，每个点更靠近中心点），其 n 个正态随机变量的采样的对应密度函数（假设其独立并服从同一分布）为：

$$f(x_1, \dots, x_n | \mu, \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}}$$

或：

$$f(x_1, \dots, x_n | \mu, \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{n/2} \exp \left(-\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2}{2\sigma^2} \right),$$

这个分布有两个参数： μ, σ^2 。有人可能会担心两个参数与上边的讨论的例子不同，上边的例子都只是在在一个参数上对可能性进行最大化。实际上，在两个参数上的求最大值的方法也差不多：只需要分别把可能性 $\text{lik}(\mu, \sigma) = f(x_1, \dots, x_n | \mu, \sigma^2)$ 在两个参数上最大化即可。当然这比一个参数麻烦一些，但是一点也不复杂。使用上边例子同样的符号，我们有 $\theta = (\mu, \sigma^2)$ 。

最大化一个似然函数同最大化它的自然对数是等价的。因为自然对数 \log 是一个连续且在似然函数的值域内严格递增的上凸函数。[注意：可能性函数（似然函数）的自然对数跟信息熵以及Fisher信息联系紧密。]求对数通常能够一定程度上简化运算，比如在这个例子中可以看到：

$$\begin{aligned} 0 &= \frac{\partial}{\partial \mu} \log \left(\left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2}{2\sigma^2}} \right) \\ &= \frac{\partial}{\partial \mu} \left(\log \left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} - \frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2}{2\sigma^2} \right) \\ &= 0 - \frac{-2n(\bar{x} - \mu)}{2\sigma^2} \end{aligned}$$


这个方程的解是 $\hat{\mu} = \bar{x} = \sum_{i=1}^n x_i / n$ 。这的确是这个函数的最大值，因为它是 μ 里头惟一的一阶导数等于零的点并且二阶导数严格小于零。

同理，我们对 σ 求导，并使其为零。

$$\begin{aligned} 0 &= \frac{\partial}{\partial \sigma} \log \left(\left(\frac{1}{2\pi\sigma^2} \right)^{\frac{n}{2}} e^{-\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2}{2\sigma^2}} \right) \\ &= \frac{\partial}{\partial \sigma} \left(\frac{n}{2} \log \left(\frac{1}{2\pi\sigma^2} \right) - \frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2}{2\sigma^2} \right) \\ &= -\frac{n}{\sigma} + \frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2}{\sigma^3} \end{aligned}$$

这个方程的解是 $\hat{\sigma}^2 = \sum_{i=1}^n (x_i - \hat{\mu})^2 / n$ 。

因此，其关于 $\theta = (\mu, \sigma^2)$ 的最大似然估计为：



在不同比例参数值下一个二项式过程的可能性曲线 = 3, $n = 10$ ；其最大似然估计值发生在其众数并在曲线的最大值处。

$$\hat{\theta} = (\hat{\mu}, \hat{\sigma}^2) = (\bar{x}, \sum_{i=1}^n (x_i - \bar{x})^2 / n).$$

性质

泛函不变性 (Functional invariance)

如果 $\hat{\theta}$ 是 θ 的一个最大似然估计，那么 $\alpha = g(\theta)$ 的最大似然估计是 $\hat{\alpha} = g(\hat{\theta})$.函数 g 无需是一个一一映射。请参见George Casella与Roger L. Berger所著的*Statistical Inference*定理Theorem 7.2.10的证明。（中国大陆出版的大部分教材上也可以找到这个证明。）

渐近线行为

最大似然估计函数在采样样本总数趋于无穷的时候达到最小方差（其证明可见于Cramer-Rao lower bound）。当最大似然估计非偏时，等价的，在极限的情况下我们可以称其有最小的均方差。对于独立的观察来说，最大似然估计函数经常趋于正态分布。

偏差

最大似然估计的偏差是非常重要的。考虑这样一个例子，标有1到n的n张票放在一个盒子中。从盒子中随机抽取票。如果n是未知的话，那么n的最大似然估计值就是抽出的票上标有的n，尽管其期望值的只有 $(n + 1)/2$.为了估计出最高的n值，我们能确定的只能是n值不小于抽出来的票上的值。

历史

最大似然估计最早是由羅納德·費雪在1912年至1922年间推荐、分析并大范围推广的。^[1]（虽然以前高斯、拉普拉斯、T. N. Thiele和F. Y. 埃奇沃思也使用过）。^[2]许多作者都提供了最大似然估计发展的回顾。^[3]

大部分的最大似然估计理论都在贝叶斯统计中第一次得到发展，并被后来的作者简化。^[1]

参见

- 均方差是衡量一个估计函数的好坏的一个量。
- 关于Rao-Blackwell定理 (Rao-Blackwell theorem) 的文章里头讨论到如何利用Rao-Blackwellisation过程寻找最佳非偏估计（即使均方差最小）的方法。而最大似然估计通常是一个好的起点。
- 读者可能会对最大似然估计（如果存在）总是一个关于参数的充分统计 (sufficient statistic) 的函数感兴趣。
- 最大似然估计跟一般化矩方法 (generalized method of moments) 有关。

参考文献

- Pfanzagl (1994)
- Edgeworth (September 1908)and Edgeworth (December 1908)
- Savage (1976), Pratt (1976), Stigler (1978, 1986, 1999), Hald (1998, 1999), and Aldrich (1997)

外部链接

- 关于最大似然估计的历史的一篇论文，作者ohn Aldrich

取自“<https://zh.wikipedia.org/w/index.php?title=最大似然估计&oldid=48050047>”

本页面最后修订于2018年1月28日 (星期日) 15:42。

本站的全部文字在[知识共享 署名-相同方式共享 3.0协议](#)之条款下提供，附加条款亦可能应用。（请参阅[使用条款](#)）

Wikipedia®和维基百科标志是[维基媒体基金会](#)的注册商标；维基™是维基媒体基金会的商标。

维基媒体基金会是在美国佛罗里达州登记的501(c)(3)[免税](#)、非营利、慈善机构。